Machine Learning Alimentos

Project Break II - ML

Maitane Barreira, Roberto Pérez, Pablo Vázquez

Queremos definir una lógica de recomendación para una app que priorice alimentos reales y saludables. La clave es evitar que el sistema recomiende ultraprocesados solo porque tengan un buen NutriScore. Por eso combinamos NutriScore (calidad nutricional) con NOVA (grado de procesado) para tomar decisiones más coherentes

Problema de negocio

Planteamiento técnico

Para resolver el problema combinamos **NutriScore** (**calidad nutricional**) **con NOVA** (**grado de procesado**) y definimos una regla de decisión en tres niveles: Altamente recomendables / Puntualmente / No recomendables. Así evitamos recomendar ultraprocesados aunque tengan un buen NutriScore.

En este proyecto, el Machine Learning no decide la recomendación final: su función es **escalar el sistema**, porque en un catálogo real NutriScore puede faltar o estar incompleto. Por eso entrenamos un modelo que predice NutriScore (A–E) usando nutrientes por 100g (kcal, proteínas, grasas, carbohidratos, fibra y azúcares).

Después, con NutriScore (real o predicho), aplicamos la misma regla NutriScore + NOVA para mantener recomendaciones consistentes en todo el catálogo.

Preparación del dataset

Partimos del dataset global y nos quedamos únicamente con productos Branded/Packaged, que son los más relevantes para un catálogo real. Después limpiamos y normalizamos nutriscore_grade (A–E) y nova_group (1–4), eliminando filas sin estas variables para poder compararlas.

Además, hicimos una limpieza de medidas no certeras: descartamos registros con nutrientes nulos o con valores fuera de rangos lógicos por 100g (por ejemplo, macros > 100g, calorías excesivas o valores negativos). Con esto reducimos ruido típico de productos mal registrados y dejamos una base más fiable para el análisis y la regla de decisión

	food_name	brand_name	brand_owner	serving_size	serving_unit
8158	AdvancePierre Flamebroiled Rib Shaped Pork Pa...	Advance Pierre	Tyson Foods Inc.	100.0	GRM
8159	ALL NATURAL GLUTEN FREE CHICKEN NUGGETS	GOLDEN PLATTER	Golden Platter Foods Inc.	85.0	GRM
8160	ALL NATURAL ROSEMARY & OLIVE OIL BASMATI RICE...	HERITAGE SELECT	SLT Foods Inc.	46.0	GRM
8161	ARTISANAL COLLECTION SPAGHETTI PASTA	BARILLA	Barilla G & R F.Lli S.P.A.	56.0	GRM
8162	AUTHENTIC BARREL RIPENED FETA CHEESE	APHRODITE	Wdh, LLC	28.0	GRM
8163	BERRY NUT BLEND BREAKFAST IN THE GO!	EMERALD	Snyder's-Lance, Inc.	42.5	g
8164	BLACK CHERRY PURE ENERGY SELTZER, BLACK CHERRY	TRUE NORTH	Energy Beverages LLC	355.0	MLT
8165	BLUE LAKE CUT GREEN BEANS	DEL MONTE	Del Monte Foods Inc.	121.0	GRM
8166	BRIE TRIPLE CRME SOFT-RIPENED CHEESE	PRSIDENT	Besnier S.A.	28.0	GRM
8167	BUFFALO STYLE WHIPPED CREAM CHEESE SPREAD	PHILADELPHIA	Kraft Heinz Foods Company	22.0	GRM
8168	CHEDDAR & SOUR CREAM FLAVORED POTATO CHIPS, C...	RUFFLES	Frito-Lay Company	42.5	GRM
8169	CHOCOLATE CAKE HOOPIE PIES, CHOCOLATE CAKE	WAXHAW BAKING CO.	US Foods, LLC	113.0	g

```
us_nutri_clean.describe()
```

	energy_kcal_100g	proteins_100g	fat_100g	carbs_100g	fiber_100g	sugars_100g
count	11137.000000	11137.000000	11137.000000	11137.000000	11137.000000	11137.000000
mean	220.699047	9.813223	10.322502	22.454071	2.185245	8.076902
std	209.900080	11.244992	15.179575	26.650634	4.606108	14.081980
min	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000
25%	69.230769	1.817121	0.640000	3.805882	0.000000	0.000000
50%	146.666667	6.301587	4.464789	11.846154	0.796460	2.345133
75%	304.705882	14.867257	13.571429	29.666667	2.083333	9.444444
max	1000.000000	100.000000	100.000000	100.000000	100.000000	100.000000

```
gl_nutri_clean.describe()
```

	energy_kcal_100g	proteins_100g	fat_100g	carbs_100g	fiber_100g	sugars_100g
count	3455.000000	3455.000000	3455.000000	3455.000000	3455.000000	3455.000000
mean	312.949206	7.715379	14.773017	35.272196	4.300860	12.201137
std	196.657932	6.686513	18.532122	27.518383	5.156939	17.341146
min	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000
25%	128.000000	3.110000	1.700000	7.200000	0.500000	1.300000
50%	345.000000	6.900000	7.500000	36.000000	3.000000	4.300000
75%	456.000000	10.000000	21.000000	60.800000	6.600000	17.000000
max	937.000000	75.000000	100.000000	100.000000	66.000000	100.000000

Generate + Code + Markdown

Maitane Barreira, Roberto Pérez, Pablo Vázquez

Preprocesado y Feature Engineering

- Continuamos con la limpieza del data set y empezamos el proceso de transformación de variables categóricas hizo posible integrar información cualitativa en el modelo.
- El escalado de variables evitó problemas derivados de diferentes unidades nutricionales.
- El feature engineering permitió crear indicadores nutricionales más interpretables, como ratios de proteína o azúcar.
- La selección de features ayudó a reducir dimensionalidad y mejorar la eficiencia del modelo.

```
#Feature Engineering
#Ratio proteína/calorías
df_us['protein_ratio'] = df_us['protein_g'] / (df_us['serving_size'] + 1)
#Ratio azúcar/fibra
df_us['sugar_fiber_ratio'] = df_us['sugar_g'] / (df_us['fiber_g'] + 1)
#Ratio grasa saturada / grasa total
df_us['sat_fat_ratio'] = df_us['saturated_fat_g'] / (df_us['fat_g'] + 1)
#Prodcuto alto en sodio
df_us['high_sodium'] = np.where(df_us['sodium_mg'] > 500, 1, 0)
```

```
#Feature Engineering
#Ratio proteína/calorías
df_gl['protein_ratio'] = df_gl['proteins_100g'] / (df_gl['energy_kcal'] + 1)
#Ratio sal/proteína
df_gl['salt_protein_ratio'] = df_gl['salt_100g'] / (df_gl['proteins_100g'] + 1)
#Producto ultra procesado
df_gl['ultra_processed'] = np.where(df_gl['nova_group'] == 4, 1, 0)
```

Modelado y resultados

Predecimos el NutriScore de un alimento utilizando seis nutrientes como variables. Se separaron los datos en conjuntos de entrenamiento y test, y se estableció un baseline con un modelo que predice la clase más frecuente, revelando un problema de desbalance. Se entrenaron tres modelos supervisados: regresión logística, Gradient Boosting y Random Forest, siendo este último el más efectivo al capturar relaciones no lineales y lograr un F1-macro superior. Se optimizaron los hiperparámetros del modelo con Grid Search CV, alcanzando un F1-macro cercano a 0.71 en el test.

```
BASELINE
Accuracy: 0.24641148325358853
F1 macro: 0.07907869481765835
              precision    recall  f1-score   support

           A       0.00      0.00      0.00       155
           B       0.00      0.00      0.00       121
           C       0.25      1.00      0.40       206
           D       0.00      0.00      0.00       171
           E       0.00      0.00      0.00       183

    accuracy                           0.25       836
   macro avg       0.05      0.20      0.08       836
weighted avg       0.06      0.25      0.10       836
```

	Accuracy	f1_macro
LogisticRegression	0.422249	0.391029
RandomForest	0.733254	0.728926
GradientBoosting	0.685407	0.682133

```
VALUACIÓN FINAL
curacy: 0.7356459330143541
macro: 0.7350109526428465
              precision    recall  f1-score   support

           A       0.78      0.81      0.79       155
           B       0.71      0.65      0.68       121
           C       0.64      0.69      0.66       206
           D       0.72      0.67      0.69       171
           E       0.85      0.84      0.85       183

    accuracy                           0.74       836
   macro avg       0.74      0.73      0.74       836
ighted avg       0.74      0.74      0.74       836
```

```
Baseline F1: 0.07907869481765835
Modelo optimizado F1: 0.7350109526428465
```


Maitane Barreira, Roberto Pérez, Pablo Vázquez

Conclusión

La conclusión principal es que NutriScore no basta para recomendar: hay productos con buena nota que siguen siendo ultraprocesados. Combinar NutriScore + NOVA genera una recomendación más consistente y aplicable a una app real.
Además, el modelo de Machine Learning aporta escalabilidad: predice NutriScore (A–E) a partir de nutrientes por 100g para cubrir productos sin score y aplicar la misma regla de decisión de forma consistente.
Como siguientes pasos, mejoraría el sistema incorporando más variables (por ejemplo sal/sodio y grasas saturadas si están), señales de ingredientes/aditivos para reforzar procesado, y validación con más catálogos para asegurar robustez.

¡Gracias!

Maitane Barreira, Roberto Pérez, Pablo Vázquez